

Mesterséges Intelligencia

Modern mesterséges neurális
hálózatok alapjai

FONTOS

- Az alábbi anyag munkavázlat, hibákat tartalmazhat. Amennyiben hibát találnak, kérem, a portálon keresztül üzenetben jelezzék, hogy melyik heti előadás, vagy jegyzet melyik részében, milyen hibát véltek felfedezni!
- Az anyagok kizárólag a Széchenyi István Egyetem 2021-2022 tavaszi félévében Mesterséges Intelligencia kurzust felvett hallgatói számára készültek, kizárólag az adott félév kurzusaihoz használható fel!
- Az alábbi hivatkozásokon megnyitott minden fájl automatikusan begyűjti a hallgató különböző egyedi azonosítóit, mely alapján beazonosítható lehet. Ennek megfelelően a hivatkozásokat ne osszák meg egymással (különösen a kurzust nem hallgatókkal), mert abból az egyedi azonosítók visszakereshetők és a személyazonosság meghatározható!
- Az alábbi anyagra vonatkozóan minden jog fenntartva!
- Az anyagok bármely részének vagy egészének nyomtatása, másolása, megosztása, sokszorosítása, terjesztése, értékesítése módosítással vagy módosítás nélkül egyaránt szigorúan tilos!

A lecke főbb témakörei

- Modern alkalmazásokban fellelhető neuron modellek főbb típusai
- Modern alkalmazásokban fellelhető topológiák
 - Konvolúciós neurális hálózatok
 - Hopfield hálók
 - Autoenkóderek
 - Generatív versengő hálók
- Neurális hálók tanítása

Modern mesterséges neurális hálózatok alapjai

modern neuron modellek

Modern neuron modellek

- A cím kissé megtévesztő
- napjainkban használt technikák alapjai akár évtizedekkel korábbra vezethető vissza
- 2010-es évek elején megugrott a mesterséges neurális hálózatok bizonyos változatainak és a hozzájuk kapcsolódó módszerek alkalmazása
- Ez részben köszönhető
 - a finomított modelleknek,
 - megfizethető olyan számítási kapacitással rendelkező hardver, amely képes már nagyobb modelleket tanítani
- A mély neurális hálózatok (deep neural network) és azok tanítása a mélytanulási (deep learning) megoldásokkal napjaink legnépszerűbb mesterséges intelligencia eszközeinek számítanak
 - 2018-tól azonban egy bizonyos fokú visszaesés figyelhető meg a kutatási eredményekben

Modern neuron modellek

- A korábbi leckében már említett mesterséges neuronok változatosak
 - vannak lineáris és nemlineáris egységek
 - A lineáris egységek bonyolultabb rendszerek esetén nem rendelkeznek kellő kifejező erővel
 - A modern megoldások esetén jellemzőbben a nemlineáris aktivációs függvényekkel rendelkező neuronokat (is) használnak

Modern mesterséges neurális hálózatok alapjai

ReLU

ReLU

- Rectified Linear Unit
- leggyakrabban használt
- negatív értékeknél 0 értéket ad vissza, míg pozitív értékekre lineáris
- egyszerű számításokat végezni vele
- gyorsabb tanulást tesz lehetővé, mint például a szigmoid aktivációs függvényvel rendelkező neuronok

ReLU

- Komoly hátrányossága, hogy a negatív értékek esetén visszaadott 0 érték csökkenti a rendszer tanulási képességét
- Előfordul, hogy a 0 értékek miatt úgy módosulnak a hálózat súlyai, hogy a neuron többé nem aktiválódik, vagyis meghal (die)
- $f_{ReLU}(x) = \max(0, x)$

Modern mesterséges neurális hálózatok alapjai

Módosított ReLU koncepciók

Módosított ReLU koncepciók

- A ReLU korlátait orvosolandó alkott meg őket
- A nemnegatív értékek esetén 0-tól eltérő válaszadás volt a cél

Leaky ReLU

- Leaky ReLU
 - a negatív értékekre vonatkozó módosítás
 - *a bemeneti érték 0,01 szerezését adja vissza*
- $f_{LReLU}(x) = \max(x; 0,01x)$

Parametrized ReLU koncepciók

- A Leaky ReLU általánosítása
 - A 0,01 szorzó helyett tetszőleges α paraméter érték
- $f_{PReLU}(x) = \max(x, \alpha x)$

Randomized ReLU

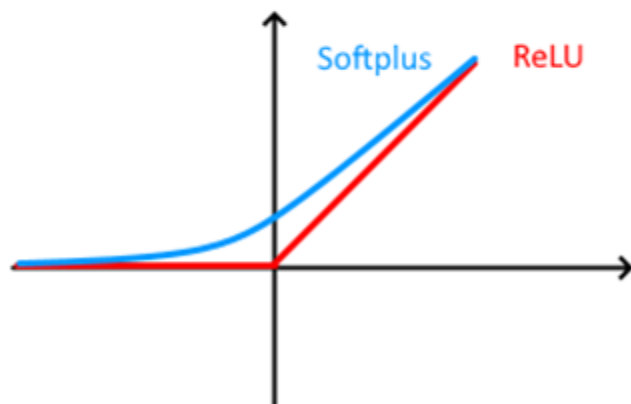
- Amikor a Leaky ReLU által alkalmazott α paraméter véletlenszerűen veszi fel az értékét

Modern mesterséges neurális hálózatok alapjai

Softplus

Softplus

- gyakran alkalmazott ReLU helyettesítő megoldás
- jellegükben hasonló értéket adnak vissza, mint a ReLU-k
- nem szakaszos



Modern mesterséges neurális hálózatok alapjai


Előrecsatolt neuron struktúrák

Neuron struktúrák

- neuron modelleket nem csak az aktivációs függvény alapján lehet megkülönböztetni,
- a neurális betöltött funkciója, illetve bekötésének módja is fontos

Előrecsatolt neuron

- A legegyszerűbb a szigmoid függvényt alkalmazó általánosított TLU, vagyis egy nem lineáris perceptron
- a neuronhoz kötött súlyozott bemeneteken túl egy bias értéket is szoktak használni
- Egyszerűen előrecsatolt (Feed Forward, FF) neuronnak is hívják



Konvolúciós neuron

- Hasonlítanak az egyszerű előrecsatolt neuronokhoz
- jellemzően egy adott neuroncsoporthoz van csak csatlakoztatva
- kiválóan alkalmas térbeli/helyzeti információk közvetítésére
 - különösen alkalmas a képi és hanginformációk feldolgozására
- Lényegében az adatot blokkokra bontja
 - egy-egy blokkot akár több különálló konvolúciós neuron csoport is felhasználhat, eltérő paraméterezés mellett lényegében eltérő lokális jellemzőket kinyerve.
- A dekonvolúciós neuronok lényegében a konvolúciós neuronok ellentettjei

Konvolúciós neuron

- A konvolúciós neuronokat alkalmazó neurális hálókbán gyakran alkalmaznak még további neuronokat
 - A klasszikus értelemben nem neuronok
 - tág értelemben, mint a hálózatba kötött egyszerű feldolgozó egységek már igen
- összevonó (pooling) neuronokat
 - a reprezentáció méretének csökkentése (downsampling)
 - képfeldolgozásnál csak kiválasztott pixelekhez tartozó jelek továbbítását jelenti
- interpolációs (interpolating) neuronokat
 - a pooling neuronok ellentetje
 - kitöltik a hiányzó, köztes értékeket..

Valószínűségi neuronok


- középérték (mean)
- szórás (deviation)
- gyakran együttesen valószínűségi (probabilistic) neuronként jelennek meg
- Céljuk jellemzően valószínűségi eloszlás információk tárolása a rendszerben
- nem rendelkeznek bias értékkel

Modern mesterséges neurális hálózatok alapjai

Visszacsatolt neuron struktúrák

Rekurrens neuronok


- jellemző a ReLU aktivációs függvény
- a bias érték használata
- a hálózat egymást követő számítási ciklusai során a korábbi eredményt is felhasználja
- lényegében egy egyszerűbb (rövidtávú) memória




Fejlett rekurrens neuronok

- hosszú rövidtávú memória (Long Short Term Memory, LSTM)
- kapuzott visszacsatolt egység (Gated Recurrent Unit, GRU)
- Az egyszerű rekurrens hálók korlátozott memóriaképességeinek leküzdésére hozták létre
- összetett architektúrával rendelkező megoldások
- a tárolt információ fejlettebb kezelésére külön bemeneti csatornákkal rendelkeznek.
- GRU az LSTM egy egyszerűsítésének tekinthető
 - Így gyorsabb

LSTM



GRU



Modern mesterséges neurális hálózatok alapjai

Architektúrák

mély előrecsatolt

- Deep Feed Forward, DFF architektúra
- lényegében egyszerű, általánosított többrétegű perceptron háló
- jellemzően ReLU, vagy nemlineáris aktivációs függvényeket alkalmaznak
- A „mély” jelzõt annak köszönheti, hogy legalább két rejtett réteg található benne
- Már régebben is számos rendszer rendelkezett ilyen, sőt még bonyolultabb struktúrákkal, de akkoriban nem tüntették ki ezeket külön a mély megnevezéssel
 - A jelentősebb eltérés a jól strukturált felépítés
- jellemző a teljes összecsatolás a rétegek között
- számos változata fellelhető a gyakorlatban

Modern mesterséges neurális hálózatok alapjai

Architektúrák

konvolúciós neurális hálózatok

- Convolutional Neural Networks, ConvNet
- egy mély előrecsatolt hálózat
 - bemeneti rétege és az első rejtett rétege közé konvolúciós és pooling neuronokat tartalmazó rétegeket helyeznek el
- célja a bemeneti adat különböző részeire vonatkozó jellemzők (features) kinyerése és az információ szűrése
- A leggyakrabban a gépi látás területén alkalmazzák
 - de képes akár audio feldolgozásra is
- A konkrét megvalósítások az architektúra részleteiben, számítási igényben és pontosságban eltérnek, azonban az alap koncepció egységes

Modern mesterséges neurális hálózatok alapjai

Architektúrák

Hopfield hálózatok

- visszacsatolt neurális hálók
- minden egyes neuron kimenete összeköttetésben áll az összes többi neuron bemenetével
 - minden neuron egyben bemeneti és kimeneti is
- Kiválóan alkalmas az önszervező tanulásra
 - a rendszert mintákkal kell ellátni, mely értékeinek megfelelően módosul a hálózat, majd konvergál az ideális értékhez.
- Jellemzően egyetlen rétegű hálózatként, vagy gyűrűként szokták ábrázolni.

Modern mesterséges neurális hálózatok alapjai

Architektúrák

Hopfield hálózatok

- visszacsatolt neurális hálók
- minden egyes neuron kimenete összeköttetésben áll az összes többi neuron bemenetével
 - minden neuron egyben bemeneti és kimeneti is
- Kiválóan alkalmas az önszervező tanulásra
 - a rendszert mintákkal kell ellátni, mely értékeinek megfelelően módosul a hálózat, majd konvergál az ideális értékhez.
- Jellemzően egyetlen rétegű hálózatként, vagy gyűrűként szokták ábrázolni.

Modern mesterséges neurális hálózatok alapjai

Architektúrák

Markov láncok

- A Hopfield hálózatok egy speciális változatának tekinthetők
- a klasszikus értelemben nem neurális háló
- Markov láncok (Markov Chain), ahol a (jellemzően) teljes összeköttetésben álló neuronok probabilisztikusak
- azt modellezi, hogy egy adott állapotból (neuronból) mekkora a valószínűsége egy másik állapotba való váltás

Modern mesterséges neurális hálózatok alapjai

Architektúrák

Boltzmann gépek

- Boltzmann Machine, BM
- szintén a Hopfield hálózatok egy speciális változata
- jelentős különbség, hogy egyes neuronok dedikáltan bemeneti neuronok, míg a többi rejtett
- egy teljes hálózati frissítést („lefutást”) követően a bemeneti neuronok kimeneti neuronná válnak
- A neuronok jellemzően bináris jellegűek
- gyakran használt változata a korlátos Boltzmann gép
 - annyiban különbözik az eredeti koncepciótól, hogy a (ki/)bemeneti neuronok és a rejtett neuronok elkülönülő csoportot (réteget) alkotnak
 - a rétegeken belül nincs kapcsolat a neuronok között
 - Ennek köszönhetően az előrecsatolt hálózatokhoz hasonló tanulás is megvalósítható az ilyen rendszerek esetében

Modern mesterséges neurális hálózatok alapjai

Architektúrák

autóenkóderek

- Autoencoder, AE
- egy speciális előrecsatolt háló
- célja az információ kódolása (tömörítése) asszociáció révén
- variációs autóenkóder (Variational Autoencoder, VAE)
 - az autóenkóderek egy speciális változata
 - más megközelítést alkalmaz
 - a bemenetek közelítő valószínűségi eloszlásain alapul, valószínűségi rejtett neuronokkal
 - elméleti háttere a Bayes-i matematikára és Boltzmann gépekre is visszavezethető

Modern mesterséges neurális hálózatok alapjai

Architektúrák

mély bizonyosságháló

- Deep Belief Network, DBN
- A variációs autoenkóderekhez és a korlátozott Boltzmann gépekhez is kapcsolható architektúra
- az egyik legelterjedtebb nem konvolúción alapuló mély architektúra volt
- Generatív modellnek tekinthető
 - egyaránt alkalmas osztályozási feladatokra és nemfelügyelt tanulással új adat generálására is
- Az egyes rétegek hatékonyan taníthatóak külön-külön is
 - mohó (greedy) megoldás segítségével
 - tudatosan rétegenkénti lokális optimumok révén próbál elérni egy kvázioptimális modellt

Modern mesterséges neurális hálózatok alapjai

Architektúrák

generatív versengő hálók

- Generative Adversarial Network, GAN
- hibrid megoldás
- valójában két hálózatból állnak
 - Egy generátor
 - mintákat kell előállítania
 - egy diszkriminátor
 - Generált és valós mintákat kell megkülönböztetnie

generatív versengő hálók

- Az ilyen hálózatok kezelése, tanítása komoly kihívást jelenthet
 - a részhálók tanítását és működésük összehangolását egyaránt meg kell valósítani
 - a lokális optimumokban való ragadás nélkül.
- Kiválóan alkalmasak élethű képek generálására
- számos GAN változat elterjedt
- leggyakrabban a különböző képek és videók generálásánál használják

Modern mesterséges neurális hálózatok alapjai

Neurális hálók tanítása

Neurális hálók tanítása

- gépi tanulás a mesterséges intelligencia egyik ága
 - nem része a mesterséges neurális hálózatok területének, de elengedhetetlen segítője
- architektúrák ideális paraméter értékeinek felügyelt és nemfelügyelt tanulással való meghatározása a cél
- Mély architektúrák - mély tanulás területe
- számos formában előfordulhat
 - a konkrét megoldások jellemzően alkalmazási területéhez köthetők.

Neurális hálók tanítása

- A tanítási módszertől függetlenül különösen fontos a megfelelő mintakészlet kialakítása
- A legtöbb mélytanuló megoldás nagymennyiségű adatot igényel
- Gyakran a neurális hálózatokon alapuló modellek fejlesztési idejének nagyobb részét teszi ki a minták előkészítése, mint a hálózat felépítése
 - Egy egyszerű objektumdetektáló gépi látás megoldás esetén is több ezer példaképre és a kapcsolódó (elvárt kimeneti) adatra szükség van (például a képen berajzolt jelölőnégyzetek és címkék formájában).

Neurális hálók tanítása

- a neuronok bemeneteihez rendelt súlyok ideális értékeinek meghatározása
- a hálózat elvárt és valós kimenetei közötti különbség által számított E hiba, vagy költségfüggvény (error/cost function) segítségével történik
- Cél az olyan súlytényező értékek megtalálása, amikkel a háló a legkisebb hibát éri el

Modern mesterséges neurális hálózatok alapjai

Neurális hálók tanítása

Perceptron Learning Rule

- perceptron tanulási szabály
- egyszerű (egyrétegű, klasszikus) perceptron hálóknál alkalmazzák
- gradiens alapú megoldást használnak
 - minden esetben a hibafüggvény lehető legnagyobb csökkenésének irányába viszi el a paramétert
 - lokális optimumot garantálva
- A módosításához használt érték meghatározására a hibafüggvény deriváltját (gradiensét) használjuk az adott súlytényezők mellett
- csak a klasszikus, küszöbfüggvényt alkalmazó hálózatok esetében használható

$$E(w) = \frac{1}{2} \sum_p \sum_j (y_d - y)^2 \qquad \frac{\partial E}{\partial w} = \frac{\partial E}{\partial w} \cdot \frac{\partial y}{\partial w} = -(y_d - y)x = -\delta x$$

Modern mesterséges neurális hálózatok alapjai

Neurális hálók tanítása

Delta Learning Rule

- Hasonlít a perceptron tanuláshoz
 - Eltérés, hogy az aktivációs függvény tetszőleges differenciálható függvény lehet
- hívják még Widrow-Hoff tanulási szabálynak is
- A modern megoldások egy speciális esete
 - Backpropagation
- nagy előrelépést jelentett a bonyolultabb aktivációs függvényeket alkalmazó hálózatok területén
- a több réteggel rendelkező topológiák esetén nem volt alkalmazható

$$\Delta w = w - w_o = -\eta \frac{\partial E}{\partial w} = +\eta \delta x$$

Modern mesterséges neurális hálózatok alapjai

Neurális hálók tanítása:
backpropagation

Backpropagation

- szintén a gradiens módszer segítségével minimalizálja a hibafüggvény értékét
- alkalmas többrétegű neurális hálók kezelésére
- hatékonysága abban rejlik, hogy a hibát a hálózat rétegein külön-külön vezeti vissza
 - ennek megfelelően módosítja a súlytényezőket
 - a láncszabály elvét veszi alapul
- felügyelt tanítási módszer
 - De alkalmazzák nemfelügyelt tanításra is

Backpropagation

- A gyakorlatban
 - a hibafüggvény meghatározására összetettebb függvényeket alkalmaznak, mint például a kereszt entrópia (Cross-Entropy), Logit, recall, precision stb
 - sztochasztikus gradiens módszereket szoktak alkalmazni
 - például az Adam keresés.

Backpropagation

- Fő lépései
 - (Tanítási minta kiválasztása)
 - Minta előre terjesztése
 - kiértékelés
 - Hiba kiszámítása
 - elvárt és eredmény kimenetek közti eltérés
 - Hiba visszaterjesztése
 - Módosított súlytényező kiszámítása
 - paraméter gradiensek
 - Súlytényezők módosítása
- A lépéseket addig ismételjük a tanítási mintákra, míg a hiba a kívánt tartományba nem esik

Modern mesterséges neurális hálózatok alapjai

Neurális hálók tanításának
kulcsfogalmai

Tanulás

- modern mély tanulási keretrendszerek
 - például a TensorFlow
 - minimális kódméret
 - egy egyszerű függvényhívás segítségével tanítható
 - egyszerű prototipizálásra alkalmas megoldás
- a mélyben zajló folyamatok megértése elengedhetetlen a komplexebb rendszerek professzionális tervezéséhez és építéséhez
- A területen fellelhető szakirodalom könnyebb megértése érdekében az alábbiakban a neurális hálók tanításánál felmerülő fontosabb kulcsfogalmak.

Neurális hálók tanításának kulcsfogalmai

- Minta (sample)
 - egy konkrét bemenet a hálózat számára,
- Tanítási minta (training sample)
 - kimondottan a hálózat tanítására szolgáló minta, jellemzően ez felügyelt tanítás esetén együtt jár az hálózat elvárt kimeneti értékével,
- Validációs minta (validation sample)
 - a neurális hálózat által megtanult modell tesztelésére szolgáló, a tanítási minták között nem szereplő minták,
- Mintakészlet (sample set)
 - minták gyűjteménye,
- Szakasz (epoch)
 - a teljes mintakészlet egyszeri átadása a hálózat számára,
- Soros, vagy szekvenciális (sequential) tanítás
 - online típusú tanítás, amikor minden egyes mintát követően hangolásra kerülnek a hálózatban használt súlyok,

Neurális hálók tanításának kulcsfogalmai

- Köteg (batch)
 - offline típusú tanítás esetén a súlyok a minták egy csoportja alapján kerül módosításra, nem pedig mintánként a soros tanítástól eltérően,
- Kiesés, vagy elhalálozás (dropout)
 - amikor a tanítási folyamat során valamilyen okból kifolyólag neuron(ok) kapcsolódását reprezentáló súlytényezők 0 értéket vesznek fel, vagyis a hálózat nem veszi figyelembe annak az értékét, „kimarad” a számításból
 - Esetenként ez lehet kívánatos (regularizálás miatt), de elkerülendő is, amit az aktivációs függvényekkel, illetve a tanuló algoritmus megfelelő paraméterezésével küszöbölnek ki,
- Túltanítás, vagy túlillesztés (overfitting)
 - amikor a modell nem valós összefüggéseket is megtanul
 - túl jól illeszkedő megoldást talál, ami általános esetekre vonatkozóan azonban már nem teljesít megfelelően
- Alultanulás, vagy alulillesztés (underfitting)
 - akkor jelentkezik, amikor nem megfelelő a hálózat mérete,
- Regularizálás
 - a túltanítás elkerülésére alkalmazott technikák
 - cél a megtanult modell általánosítása

Neurális hálók tanításának kulcsfogalmai

- Generalizálás
 - a neurális hálók alapvető képessége a mintákból való általánosított (generalizált) jellemzők megtanulása,
- Tanulási sebesség (learning rate)
 - a súlytényezők módosításának mértékét befolyásoló paraméter,
 - kicsi érték esetén a tanulás lassú, de stabilan konvergál
 - nagy érték esetén a tanulás gyors, de előfordulhat, hogy nem konvergál
 - általában értékét fokozatosan csökkentik
- Hiper-paraméterek (hyperparameters)
 - a hálózatra jellemző paraméterek
 - a struktúrát írják le
 - például a rétegek és az azokban található neuronok száma, vagy a tanulási sebesség,

Neurális hálók tanításának kulcsfogalmai

- Adat dúsítás (data augmentation)
 - a mély tanulási módszerek hatalmas adatigénye
 - gyakori problémát okoz az olyan területeken, ahol az adatgyűjtés költséges, vagy nehezen megoldható
 - a meglévő mintákból új mintákat állítunk elő és ezeket is felhasználjuk a tanítás során
- Egy lövéses (one-shot) tanulás
 - egyetlen minta alapján képesek a neurális hálózat paramétereit hangolni
 - egy kutatási irány a hiányos adathalmazok orvoslására
- Átadásos tanulás (transfer learning)
 - olyan technikák, amelyek egy már valamilyen mintakészlet alapján betanított hálózatot használunk fel
 - lényegében a forrásként használt modellben található tudást adja át az új hálózatunknak

Felhasznált források

- <https://selfdrivingcars.mit.edu/deeptraffic/>
- <https://www.asimovinstitute.org/neural-network-zoo-prequel-cells-layers/#comments>
- <http://www.asimovinstitute.org/neural-network-zoo/>
- <https://towardsdatascience.com/the-mostly-complete-chart-of-neural-networks-explained-3fb6f2367464>
- <http://www.deeplearningbook.org/>
- <https://deeplearning.mit.edu/>
- <https://arxiv.org/pdf/1602.05179.pdf>
- <https://eng.uber.com/deep-neuroevolution/>
- <https://arxiv.org/pdf/1703.03864.pdf>
- <http://www.cs.huji.ac.il/~shais/UnderstandingMachineLearning/>
- <https://mml-book.github.io/>
- <http://thmlbook.com/wiki/doku.php>
- <http://d2l.ai/>
- <https://christophm.github.io/interpretable-ml-book/>
- https://www.researchgate.net/figure/CRConvNet-the-Character-Recognition-Convolutional-Neural-Network-architecture_fig14_235665033
- <https://arxiv.org/abs/1605.07678>
- <https://arxiv.org/pdf/1412.6980.pdf>
- <https://medium.com/@karpathy/yes-you-should-understand-backprop-e2f06eab496b>
- <https://openai.com/blog/better-language-models/>
- <https://openai.com/blog/language-unsupervised/>
- http://cs231n.stanford.edu/slides/2017/cs231n_2017_lecture5.pdf
- http://axon.cs.byu.edu/~martinez/classes/678/Papers/Hopfield_Chapter.pdf
- <https://cs.stanford.edu/~quocle/tutorial2.pdf>
- <https://mattmazur.com/2015/03/17/a-step-by-step-backpropagation-example/>
- <https://www.anotsorandomwalk.com/backpropagation-example-with-numbers-step-by-step/>