

Mesterséges Intelligencia

Mesterséges neurális hálózatok
alapjai

FONTOS

- Az alábbi anyag munkavázlat, hibákat tartalmazhat. Amennyiben hibát találnak, kérem, a portálon keresztül üzenetben jelezzék, hogy melyik heti előadás, vagy jegyzet melyik részében, milyen hibát véltek felfedezni!
- Az anyagok kizárólag a Széchenyi István Egyetem 2021-2022 tavaszi félévében Mesterséges Intelligencia kurzust felvett hallgatói számára készültek, kizárólag az adott félév kurzusaihoz használható fel!
- Az alábbi hivatkozásokon megnyitott minden fájl automatikusan begyűjti a hallgató különböző egyedi azonosítóit, mely alapján beazonosítható lehet. Ennek megfelelően a hivatkozásokat ne osszák meg egymással (különösen a kurzust nem hallgatókkal), mert abból az egyedi azonosítók visszakereshetők és a személyazonosság meghatározható!
- Az alábbi anyagra vonatkozóan minden jog fenntartva!
- Az anyagok bármely részének vagy egészének nyomtatása, másolása, megosztása, sokszorosítása, terjesztése, értékesítése módosítással vagy módosítás nélkül egyaránt szigorúan tilos!

A lecke főbb témakörei

- Biológiai neurális hálózatok
 - Neuronok és működésük
- Mesterséges neuron modell
- Perceptron modell
- Radiális bázisfüggvény neurális hálózatok
- Celluláris neurális hálózatok
- Kohonen-hálók

Mesterséges neurális hálózatok alapjai

Biológiai neurális hálózatok

Biológiai neurális hálózatok

- Az állatokban (így az emberekben is) megtalálható ideghálózat
- A fejlettebb állatok idegrendszerei nagyon összetettek, jellemzően két fő részre osztják
 - a központi idegrendszere
 - része az agy és a gerincvelő
 - a környéki idegrendszere
 - például a szomatikus és az autonóm idegrendszer is tartozik

Biológiai neurális hálózatok

- Maga az idegszövet két fő sejtcsoport alkotja
 - egyrészt az idegsejtek, vagyis a neuronok
 - amely az ingerület kezelésére szolgál
 - másrészt a gliasejtek
 - melyek többek között a támasztásért és az agy takarítási funkcióiért is felelősek
- Az összetett, intelligens viselkedési minták létrehozásában a neurális hálózatnak van szerepe, melyet az idegsejtek szinapszisokon keresztüli kommunikációja valósít meg


Mesterséges neurális hálózatok alapjai

Biológiai neuron

Biológiai neuron

- A neuronok tipikus felépítése
 - a sejttest,
 - melyben található a sejtmag,
 - sejttestből ágaznak ki a dendritek,
 - melyek az ingerületek (vagyis az információ) felvételét teszik lehetővé
 - valamint az axonok,
 - melyeken keresztül továbbításra kerül a dendritek által felvett információ
 - Az axonokat jellemzően egy zsírban gazdag, úgynevezett myelinhüvely védi
- az idegrendszer alapegységének tekinthetők
- az információ áramlásáért és feldolgozásáért felelősek

Biológiai neuron



- Az emberi tudat és intelligencia az agyat alkotó megközelítőleg 90 ($\sim \pm 10$) milliárd neuron és az e neuronok közötti kapcsolatok révén áll elő.
- Nagyon sokáig úgy tartották, hogy a neuronok az egyetlen olyan sejtek, melyekből nem keletkezik új az idősebb korban
 - a legújabb megfigyelések felnőttek esetében is alátámasztották új idegsejtek létrejöttét

Mesterséges neurális hálózatok alapjai

Biológiai neuronok főbb típusai

Biológiai neuronok főbb típusai

- Az idegrendszer különböző területein megtalálható, eltérő célú neuronok nagyon változatos jellemzőkkel bírnak, mind megjelenésben, mind biokémiai tulajdonságait tekintve.
- Többféle csoportosítás létezik

Biológiai neuronok főbb típusai

- **Struktúra szempontjából**
 - unipoláris neuronok
 - melyek az egyszerűbb állatokban, rovarokban a leggyakoribbak
 - pszeudounipoláris neuronok
 - a szenzoros neuronok, melyek fizikai és kémiai jelek érzékelésére szolgálnak (például a hőérzet, vagy az ízérezékelés)
 - jellemzően ketté ágazó axonnal rendelkeznek
 - bipoláris neuronok
 - pszeudounipoláris neuronokhoz hasonlóan jellemzően a szaglász és látás érzékelésében játszanak szerepet
 - motoros neuronok az agytól a gerincig és a gerinctől az izmokig, szervekig találhatóak meg az idegrendszerünkben,
 - multipoláris poláris neuronok
 - egy axonnal és számos dendrittel rendelkeznek.

Mesterséges neurális hálózatok alapjai

Szinapszis

Szinapszis

- A neuronok szinapszisok révén alakítanak ki kapcsolatokat egymás között
 - lehetnek elektromos átvitelűek, a sejtmembránok közötti ioncsatornák révén,
 - vagy kémiaiak, az akciópotenciál (idegsejtek polarizációja és depolarizációja) hatására kibocsátott neurotranszmitterek révén,
 - melyek főként az idegrendszerben termelődő ingerületátvivő anyagok,
 - mint például dopamin, szerotonin vagy az oxitocin és az adrenalin és a dendriteken található különböző receptorok által továbbítják az információt.

Mesterséges neurális hálózatok alapjai


Threshold Logic Unit

Threshold Logic Unit

- Az első biológiai neuronok működését modellező (mesterséges neuron) egység
- küszöbérték-logikai egység
- McCulloch és Pitts alkották meg
- durva modellje a (biológiai) neuronoknak
 - számos lényegi jellemzőt nem vesz figyelembe
 - azonban szerénysége ellenére viszonylag erős kifejezőerővel bír
- Alapvetően a bemenetekből, a kimenetből, valamint a feldolgozó egységből áll.

Threshold Logic Unit

- bemenetén a többi neurontól (vagy bemenettől) származó értékek
 - lényegében a szinapszist reprezentálja
- amennyiben több neuront kapcsolunk össze, akkor e kapcsolatok erősségét (a különböző neuronok kimenetéhez rendelt) súlytényezőkkel szokás reprezentálni.







Threshold Logic Unit

- A feldolgozó egység határozza meg a mesterséges neuron kimenetét a bemenetek függvényében
- Az eredeti TLU modellben egy egyszerű küszöbfüggvényt alkalmaztak
- Ha a bemenetek (súlyozott)összege eléri a küszöb szintjét, akkor a kimeneten 1-es jelenik meg, ellenkező esetben 0 az eredmény
- A gyakorlatban azonban neuron kimenetének kiszámításához a szignumfüggvényt szokás alkalmazni,
 - vagyis megnézzük, hogy nemnegatív-e a (súlyozott)bemenetek összegének és a küszöbértéknek a különbsége

Mesterséges neurális hálózatok alapjai

Tipikus aktivációs függvények

Tipikus (hagyományos) aktivációs függvények




Mesterséges neurális hálózatok alapjai

Topológiák

Topológiák

- önmagában egy nagyon primitív műveletet végző egység
- e módon működő neuronokat különböző konfigurációk (topológiák, architektúrák) szerint lehet egymáshoz kapcsolni
- együttesen már komplexebb problémák leírására is alkalmassá teszi
- A hálózatba kötött TLU-k képesek lineárisan szeparálható problémák megoldására
- Lineárisan szeparálhatónak tekintjük az Euklideszi térben lévő pontok két halmazát, ha létezik legalább egy olyan pont, egyenes, sík, vagy hipersík, amelynek egyik oldalán az egyik halmaz elemei, míg a másik oldalán a másik halmaz elemei találhatók.

Lineáris szeparálhatóság




Lineárisan szeparálható, valamint lineárisan nem szeparálható osztályok


Topológiák

- Topológia szerint alapvetően négy fő csoportba oszthatóak a neurális hálók:
 - az egyrétegű (single-layer), előrecsatolt (feedforward) hálózatok
 - az egyrétegű, visszacsatolt (recurrent, feedback, vagy interactive) hálózatok
 - a többrétegű (multilayer), előrecsatolt hálózatok
 - a többrétegű, visszacsatolt hálózat
- A mesterséges neurális hálózatok esetén az azonos szinten lévő neuronokat úgynevezett rétegekbe (layer) rendezik
- Amennyiben a hálózatnak egyetlen bemeneti és egyetlen kimeneti rétege van, akkor egyrétegű hálózatról beszélünk
- Többrétegű hálók esetében a bemeneti- és kimeneti rétegek közötti összes többi réteget rejtett réteg(ek)nek hívjuk, melyekből több is lehet a hálózatban
- Rétegenként a neuronok száma eltérő lehet
- Az előrecsatolt hálózatok esetén a bemeneti réteg felől szigorúan csak a kimeneti réteg irányába halad az információ, míg visszacsatolt hálózatoknál az egyes neuronok kimenete az azonos, vagy korábbi rétegek bementére is rá lehet kötve, vagyis az információ visszacsatolásra kerül.


Tipikus (hagyományos) topológiák




egyrétegű előrecsatolt



egyrétegű visszacsatolt



többrétegű előrecsatolt



többrétegű visszacsatolt

Topológiák

- Sekély, vagyis shallow hálónak nevezik a (jellemzően) maximum egyetlen rejtett réteggel rendelkező modelleket
- A modern népszerű megoldások esetén az úgynevezett mély (deep) neurális hálók a modell architektúrájára utalnak
 - a mély megoldások jellemzően jóval több rejtett réteggel rendelkeznek
- Természetesen ugyanannyi neuron felhasználásával készíthető sekély és mély hálózati topológia is
 - a vizsgálatok megmutatták, hogy a több réteggel rendelkező megoldások komplexebb modellek megalkotására is képesek.
- Természetesen a fentiektől eltérő, más jellegű hálózati topológiák is megfigyelhetők a területen, mint például az Elman, Jordan, vagy a versengő (competitive) hálók. A topológia nagyban meghatározza a neurális háló által modellezhető problémák körét.

Mesterséges neurális hálózatok alapjai

Tanulás

Tanulás

- a mesterséges neurális hálózatok valóban könnyen implementálható, egyszerű alkotóelemekből felépülő, nagyon hatékony modell megalkotására képesek
- A mesterséges neuronok változatos működése, összekapcsolásaik elrendezése, valamint a rendszer paraméterei egyaránt hatással vannak a hálózat által reprezentált modellre (vagyis lényegében a tudásra)
- E jellemzők (neuron típus, háló elrendezése, súlytényezők stb.) ideális meghatározása azonban egy nagyon bonyolult folyamat
 - egyes neurális hálózatok esetén ez csak kompromisszumok révén oldható meg
 - jellemzően a háló tanulási folyamata során történik.

Tanulás

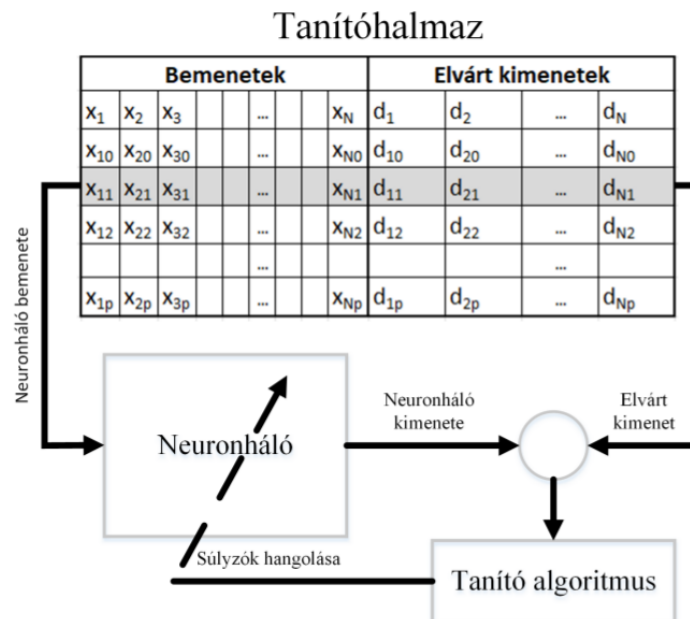
- A neurális hálózatoknál is alkalmazott gépi tanulás technikák alapvetően három fő kategóriába sorolhatók (paradigma szerint)
 - (1) felügyelt (supervised);
 - (2) nem felügyelt (unsupervised);
 - illetve (3) megerősítéses (reinforcement) tanulás

Tanulás

Felügyelt tanulás

összetartozó be- és kimeneti értékek, úgynevezett tanítópárok állnak rendelkezésre

A paraméterek hangolásának az a célja, hogy a számított válaszok a kívánt válaszokkal minél jobban megegyezzenek, a hálózat kimenete és a kívánt kimenet közötti különbség csökkenjen.



Tanulás

Nem felügyelt tanulás

A példákhoz nincs „külső segítség”, azaz nem adottak az osztálycímkek.

Az adathalmazt a modell önállóan dolgozza fel olyan minták és információk felfedezésére, amelyeket korábban nem fedeztek fel.

Leggyakoribb feladatok:

- minták közötti hasonlóság megállapítása (formafelismerés);
- minták csoportosítása (klaszterezés);
- van –e korreláció az adatok között

Tanulás

Megerősítő tanulás

A tanítókészlet bemeneti mintázatokból áll, a tanítási ciklus befejezése után egy megerősítő érték jelzi, hogy az eredmény helyes volt-e vagy nem. Ez alapján történik a súlytényezők tanítása.

Egy lehetséges tanítás, hogy a helyes válaszokra kapott bemeneteket és a neuronháló kimenetén kapott eredményt hozzáadjuk a tanító halmazhoz. A rossz válaszok nem kerülnek be a tanítóhalmazba.

Tanulás

- A tanulás módja alapján két fő csoportba sorolhatóak a neurális hálózatoknál használt tanuló algoritmusok:
 - (1) a struktúra;
 - illetve (2) a paraméter tanulás.

Tanulás

- A tanulási megoldások további szempontok szerint is csoportosítható, mint például a tanulás lefolyása:
 - (1) online;
 - (2) offline

online: a súlyok módosítását minden tanító pont, és a kapott output összehasonlításnál elvégezzük

offline (batch): kiszámoljuk a hibát minden be-kimeneti tanítópárra, de a súlymódosítást csak egyetlenegyszer végezzük el egy tanítási cikluson belül

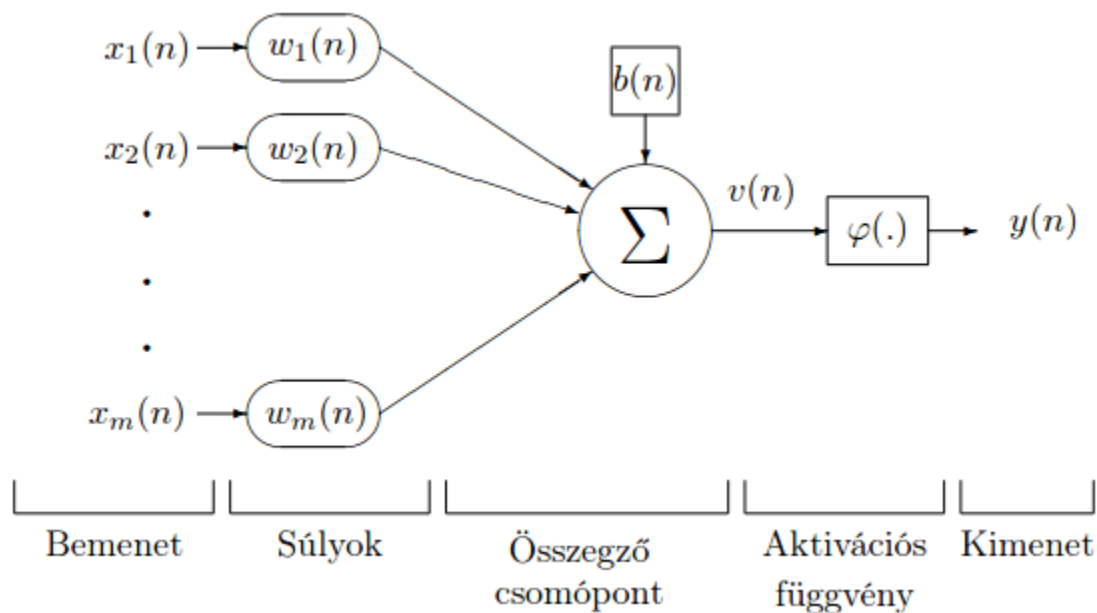
Mesterséges neurális hálózatok alapjai

Perceptron

Perceptron

- 1958, Rosenblatt
 - Cornell Egyetem
- tanulni is képes neurális hálózat
- hardverként is kivitelezésre került
- nem más, mint egy előrecsatolt, egyrétegű, TLU-kból álló hálózat


Egyszerű perceptron felépítése



Perceptron

- Többrétegű perceptron (Multi-Layer Perceptron, MLP)
 - a be- és kimeneti rétegeken túl legalább egy, vagy több rejtett réteggel is rendelkezik
 - Kezdetben a perceptronok is bináris működésűek voltak (a TLU-hoz hasonlóan)
 - belátható, hogy kizárólag lineáris neuron modellek esetén meghatározható egy ekvivalens be- és kimeneti rétegből álló háló
 - Rájöttek, hogy az aktivációs függvény lecserélésével sokkal komplexebb modelleket is megalkothatnak
 - különösképp a szigmoid átviteli függvényt (és a hasonló függvényt, mint a hiperbolikus tangens) kezdték alkalmazni (de az eredeti perceptron bináris kimenetű)
 - Ez lett általánosan az előrecsatolt neurális háló (Feed Forward Neural Network, FFNN)

Többrétegű perceptron



Perceptron

- A rétegek számával sokkal komplexebb műveletek végrehajtására is képessé váltak a perceptronok
 - nagy népszerűsége tettek szert.
- Azonban a leírható modellek bonyolultságával együtt egy új probléma is megjelent
 - az ideális paraméterek (bias és/vagy súlytényezők, küszöb értékek) megtalálása
 - különösen nagy rétegszám esetén.
- Az akkori hardverek kapacitása nem tette lehetővé, hogy az ilyen mély hálók esetén hatékonyan megtalálják az ideális paramétereket, ami jelentősen visszavetette az ilyen típusú megoldások alkalmazását (sokan a tartóvektor-gepek, support vector machine felé fordultak, melyek esetén könnyebb az ideális paraméterek meghatározása).

Perceptron

- A leggyakoribb alkalmazások a különböző osztályozási feladatok területén figyelhetők meg,
 - beszéd- és képfelismerés külön kiemelendő
- Bebizonyították, hogy az MLP-k univerzális approximátorok
 - tetszőleges nem lineáris függvény közelíthető meg elégséges neuronszám esetén, így regresszió analízis segítségével alkothatók modellek

Mesterséges neurális hálózatok alapjai

Radiális Bázisfüggvény Hálók

Radiális Bázisfüggvény hálók


Bázisfüggvényeken alapuló hálózatokat Broomhead és Love vezettek be 1988-ban, majd Moody, Darken 1989-ben

- két aktív rétege:
 - a bemeneti réteg, mely egy nemlineáris leképezést végez
 - a kimeneti réteg, amely a bázisfüggvények és a súlytényezők lineáris kombinációját valósítja meg

minden bázisfüggvény-kimenet pároshoz tartozik egy súlytényező

A háló bemeneteinek száma adja meg a bázisfüggvények terének dimenzióját

Radiális Bázisfüggvény hálók



Radiális Bázisfüggvény hálók

A háló kimenetének számítása:

- Összegzés:

$$y_i = \sum_{k=0}^N g(\underline{X}, \underline{c}_k, \sigma_k) w_{i,k}$$

\underline{X} bemeneti vektor

\underline{c}_k k-dik bázisfüggvény középpont vektora

σ_k k-dik bázisfüggvény szórása

a háló érzékenyebb, viszont a kimenete nem normalizált érték

- Szorzat:

$$y_i = \prod_{k=0}^N g(\underline{X}, \underline{c}_k, \sigma_k) w_{i,k}$$

előnyös, mert a háló kimenete a $[0,1]$ intervallumban van normalizálva

Ebben az esetben egyik bázisfüggvény kimenete sem lehet nulla

Radiális Bázisfüggvény hálók

Bázisfüggvények

Bázisfüggvényként alkalmazható minden körszimmetrikus nemlineáris függvény


Gyakran alkalmazott bázisfüggvények:

- Gauss-függvény

$$g(\underline{X}, \underline{c}_k, \sigma_k) = e^{\frac{-\|\underline{X} - \underline{c}_k\|^2}{\sigma^2}}$$

- Multikvadratikus függvény $g(x, c) = (x^2 + c^2)^{\frac{1}{2}}, c > 0, x \in R.$

- Inverz multikvadratikus függvény $g(x, c) = \frac{1}{(x^2 + c^2)^{\frac{1}{2}}}, c > 0, x \in R.$



Radiális Bázisfüggvény hálók

RBF neuronhálók tanítása

- Bázisfüggvények elhelyezése:

Követelmény: bázisfüggvényeknek le kell fedniük a teret

Ha a háló bemeneteinek száma n , akkor egy n dimenziós teret kell lefednünk.

A bázisfüggvények átfedésének mértéke is nagyban befolyásolja a háló approximációs minőségét.

1. Egyszerűbb esetekben a bázisfüggvények egyenlő távolságra helyezkednek el egymástól, és a szórásuk úgy van megválasztva, hogy az egész teret lefedjék.

2. Közeppontok önszervező kiválasztása: klaszterező algoritmus segítségével például K-közép algoritmus

3. Közeppontok felügyelt kiválasztása


A közép pontok és a bázisfüggvények tanítása a súlytényezőkkel analóg módon is történhet, a hiba minimumát keresve.

4. Véletlenszerűen kiválasztunk m darabot a tanító pontok közül: kevés tanító pont esetén súlyértékek meghatározása egy lineáris egyenletrendszer megoldásával történhet


Radiális Bázisfüggvény hálók

RBF neuronhálók tanítása

- Bázisfüggvények elhelyezése



Bázisfüggvények egyenletes elosztása egyváltozós bemenetre



Példa egy kétdimenziós tér bázisfüggvényekkel való lefedésére

Radiális Bázisfüggvény hálók

RBF neuronhálók tanítása lépések:

1. Meghatározzuk a háló topológiáját, bázisfüggvények típusát, bázisfüggvények számát, a bázisfüggvények elhelyezésének módját, véletlenszerűen meghatározzuk a súlytényezők kezdőértékeit.

2. Kiszámoljuk a háló kimenetét (y) az x_k bemenet függvényében.

3. Ismerve a bemeneti-kimeneti tanító párokat (x_k, d_k), a második lépésben kiszámolt kimenetre kiszámoljuk a hibát

$$\delta = d_k - y.$$

4. Módosítjuk a súlytényezőket a delta-szabállyal.

$$w_{i,n} [k + 1] = w_{i,n} [k] + \mu (\delta_i) g (\underline{X}, \underline{c}_k, \sigma_k) \quad n = 1, \dots, N, i = 1, \dots, M.$$

5. Megismételjük minden egyes ki-bemeneti párra a tanító halmazból.

6. Egy teljes ciklus végén kiszámolunk egy négyzetes hibát

$$E = \sum_{i=1}^M \delta_i^2$$

Ha a hiba egy adott szint alá csökken, vége a tanításnak, ha nem, újra vesszük a be-kimeneti párokat, és megismételjük az algoritmust a 2. ponttól.



Radiális Bázisfüggvény hálók

Az RBF neuronhálók fontosabb alkalmazási területei:

- többváltozós függvények approximációja
- minták osztályba sorolása
- adattömörítés
- nemlineáris irányítási feladatok
- rendszermodellezés

Radiális Bázisfüggvény hálók

Közelítsük az $f(x) = x^3 - x$ függvényt a $[-2, 2]$ intervallumon, ha a megfigyelések a -2 és 2 közötti, egymástól egyenlő távolságban lévő (azaz ekvidisztáns) alappontokban a hiba nélkül mért függvényértékek. Konkrétan 10 tanító pontot választottunk.



RBF: 11 neuron a rejtett rétegben


RBF2: 5 neuron \rightarrow túl kevés

RBF3: 50 neuron \rightarrow túl sok

Radiális Bázisfüggvény hálók

Közelítsük az $f(x) = x^3 - x$ függvényt a $[-2, 2]$ intervallumon, ha a megfigyelések a -2 és 2 közötti, egymástól egyenlő távolságban lévő (azaz ekvidisztáns) alappontokban a hiba nélkül mért függvényértékek.


Csökkentsük le a tanító pontok számát 6 db-ra!



RBF1: 11 neuron a rejtett rétegben

RBF2: 25 neuron → túl sok

Radiális Bázisfüggvény hálók



Két normális eloszlás szeparálása RBF-fel

A rész: túl sok (90 db) neuron, rosszul általánosít.

B rész: megfelelő számú (30 db) neuron, jól általánosít

Optimális módon a két normális eloszlást egy egyenes választaná ketté

Mesterséges neurális hálózatok alapjai

Celluláris neurális hálózatok

Celluláris Neurális Hálózatok

- Chua és Yang, 1988
- Egyszerű analóg feldolgozóegységek (cellák) hálózata
 - Természetesen diszkrét rendszereken is megvalósítják
 - Képes a boole-függvények kifejezésére, de akkori elterjedésének oka a masszívan párhuzamos architektúra, ami nagyon gyors jelfeldolgozást tett lehetővé
 - Gyakran alkalmazták kamerákba ágyazott számítógépeken különböző jelfeldolgozási célokra, másodpercenként több tízezer képkockát képes feldolgozni
- Számos változata létezik

Celluláris Neurális Hálózatok

- Minden cella kapcsolatban áll a közvetlen szomszédjával
- A legjellemzőbb elrendezés a 2-Dimenziós, de más megoldások is fellelhetők a szakirodalomban

A cellák csak a szomszédaikkal vannak kapcsolatban. Minden cella állapotát befolyásolhatják a szomszédok kimeneti és bemeneti értékei. A kölcsönhatások erősségét az A illetve B mátrixok határozzák meg.

(i, j) cella állapotegyenlete:



$$\frac{dx_{ij}(t)}{dt} = -x_{ij}(t) + \sum_{(k,l) \in \mathcal{N}(i,j)} A(i,j;k,l) \cdot y_{kl}(t) + \sum_{(k,l) \in \mathcal{N}(i,j)} B(i,j;k,l) \cdot u_{kl} + z(i,j;k,l)$$

u_{ij} , x_{ij} , and y_{ij} az (i,j) cella bemenete, állapota és kimenete
templete: A, B 3x3-as mátrix, z skalár

kimenet egyenlete: $y_{ij}(t) = f(x_{ij}(t)) = \frac{1}{2} (|x_{ij}(t) + 1| - |x_{ij}(t) - 1|)$

A művelet során a cellák párhuzamosan működve és kölcsönhatva eljutnak egy stabil állapotba, amely valójában az állapotegyenletek megoldása

Több réteg cella bonyolult parciális differenciálegyenletek oldhatók meg



Mesterséges neurális hálózatok alapjai

Önszervező, Kohonen hálók


Kohonen hálók

- Az önszervező (vagy önrendező) hálók (Self-Organizing Map, SOM)
- elméletét Teuvo Kohonen mutatta be 1981-ben
- Sokdimenziós adatok hatékony vizualizálására alkalmas
 - a dimenziók egy hálóba (map) redukálása (diszkrétizálása) révén
 - csökkenti az adat mennyiségét a hasonlóságok alapján
 - megőrzi a legfontosabb topológiai információkat és a metrikus kapcsolatokat az elsődleges adatelemek között
- Gondolhatunk rá úgyis, mint egy absztrakciós eljárásra
- A leggyakrabban 2-dimenziós kimenetű (vagyis a redukált adathalmazú, a hálójú) formában találkozhatunk vele, de előfordul 1-, vagy ritkábban akár több-dimenziós változat is


Kohonen hálók

- az agyban is megfigyelhető jelenségre vezethető vissza
 - azonos érzékelésért felelős neuronok egymáshoz nagyon közeli területen helyezkednek el
 - és az azonos, vagy nagyon hasonló stimulusra (pl. orientáció, frekvencia) aktiválódó neuronok az adott területen belül is egymáshoz közel helyezkednek el
- A Kohonen hálók esetén a bemeneti réteg (vagy vektor) minden elemét hozzákötjük a háló minden neuronjához (csomópontok, vagy node-ok a számítási, vagy computational rétegben)
 - lényegében teljesen összekötött rétegről van szó
- A neuronok itt nem rendelkeznek semmilyen feldolgozási funkcióval
- a bemeneti vektor értékei és az egyes neuronok súlytényezői közötti eltérést veszi figyelembe
- Az a súlytényező kerül kiválasztásra, amelyik a legkisebb diszkriminancia értékkel rendelkezik, ahol a diszkriminanciafüggvény leggyakrabban Euklideszi távolság, azonban lehet másféle is, mint például a koszinusz távolság.

Kohonen hálók



Kohonen-neuronháló



Kohonen-neuronháló szerkezete oldalirányú
kapcsolatokkal:

ha a processzáló elem önmagára való
visszacsatolás, akkor gerjesztő, míg a többi
oldalsó kapcsolat gátló.

Kohonen-hálók





A Kohonen-háló fontosabb paraméterei:

- bemenetek száma (P);
- az összneuronok (processzáló elemek, csomópontok) száma (N);
- súlymátrix ($W - N \times P$ méretű);
- a neuronok topológiai elhelyezkedése (alkalmazott topológia) $l = 1$,
1D elhelyezkedés, $l = 2$, 2D elhelyezkedés, $l = 3$, 3D elhelyezkedés;
- V mátrix a csomópontok pozíciójának az eloszlásáról ($V - m \times l$ méretű), V mátrix megadja a topológiáját a csomópontoknak.

Kohonen-hálók


Topológiák:

- Lineáris rácstopológia
- Gyűrűs rácstopológia
- Négyzetes rácstopológia
- Hexagonális rácstopológia
- Véletlenszerűen generált rácstopológia



Kohonen-hálók

Kohonen-háló négyzetes rácstopológia




Kohonen-hálók

Kohonen-térkép: egy hálóban található csomópontoknak a súlyvektortérben való ábrázolása.


A súlyvektor térben minden neuront ábrázolunk egy pontként, ahol a pont koordinátáit az illető neuron súlyai határozzák meg.

A szomszédos neuronok egymással össze vannak kötve az alkalmazott rácestopológia szerint.

ha sikeres a tanítás, a Kohonen-térképen megjelenített háló kifeszül a rácestopológiának megfelelően.



Kohonen-háló



Kohonen-térkép tanítás kezdetén

Kohonen hálók

- A tanításhoz egy kezdeti súlytényező konfigurációt kell létrehozni
- jellemzően ezres nagyságrendű mintakészletre van szükség
 - tanulási ciklus során egyet-egyet véletlenszerűen kiválasztva átadunk a hálónak
 - Az adott minta vektorhoz legjobban illeszkedő súlyokkal rendelkező csomópontot (Best Matching Unit, BMU, legjobban illeszkedő egység, vagy győztes neuron) megkeressük a diszkriminanciafüggvény segítségével,
 - majd úgy módosítjuk a súlyt, hogy az még jobban hasonlítson a mintához (vagyis csökkenjen a diszkriminancia értéke)
 - Nem csak a BMU súlytényezőjét módosítjuk, hanem az azzal szomszédos neuronokét is, szintén úgy, hogy jobban illeszkedjen az aktuális mintához, azonban a végrehajtható módosítás (tanulás) mértéke a BMU-tól való távolsággal fordítottan arányos
 - Ez a folyamat ismétlődik
 - a tanulás előrehaladtával a súlytényező egyre kisebb mértékű módosítását engedjük csak meg, a figyelembe vett szomszédos csomópontok száma is csökken
 - Erre azért van szükség, hogy kezdetben gyors, jelentős változások mehessenek végbe, majd egyre kisebb, finomhangolás jellegű módosítások történjenek.

Kohonen-hálók

BMU győztes neuron meghatározása: általában a minta és a egyes neuronok közötti euklideszi távolság alapján

$$c(t) = \arg \min_i \{ \|x(t) - w_i(t)\| \}$$

Győztes neuron súlyának módosítása (normalizált Hebb-szabály):

μ tanulási együttható

$$\underline{w}_{i^*} = \underline{w}_{i^*} + \mu (\underline{X} - \underline{w}_{i^*})$$


Szomszédos neuronok súlyait is módosítjuk: $\underline{w}_i = \underline{w}_i + \mu \Phi(\underline{r}_i, \underline{r}_{i^*}) (\underline{X} - \underline{w}_{i^*})$

Közeli neuronok súlyait nagyobb, távolabbiakét kisebb mértékben pl Gauss-függvénnyel
A tanítás során kezdetben a súlytényezőket nagy lépéssel kell tanítani (μ tanulási együttható értéke nagy), és a szomszédsági függvénnyel a szomszédsági fokot is nagyra kell állítani. Ezáltal lehetővé tesszük a mintáknak egy adott halmazból egy másik halmazba való vándorlását.


A tanítás során fokozatosan kell csökkenteni a tanítási együtthatót és a szomszédsági fokot. A tanítási ciklus végén a szomszédsági fokot le kell csökkenteni, hogy csak a győztes neuron súlytényezőit hangoljuk, ellehetetlenítve a mintáknak az osztályok közötti vándorlását.

Kohonen-hálók


Szomszédsági fok




Rectangular SOM grid (size 1)




Rectangular SOM grid (size 2)




Rectangular SOM grid (size 1)



Rectangular SOM grid (size 2)

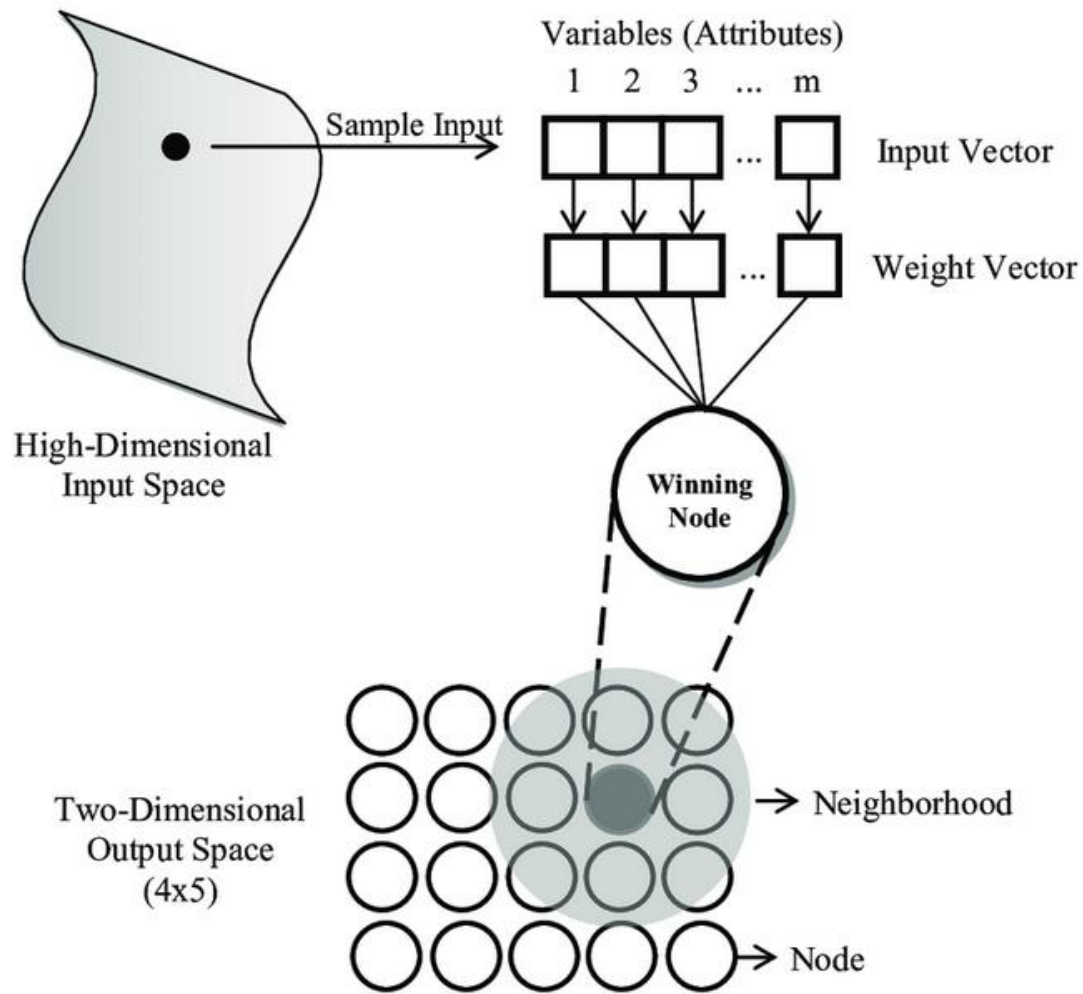


Hexagonal SOM grid (size 1)



Hexagonal SOM grid (size 2)

Kohonen-hálók




Kohonen-hálók

Utazó Ügynök Probléma (TSP) megoldása Kohonen-háló segítségével

Az utazó ügynök feladatot a következőképpen fogalmazhatjuk meg: adott N város, melyeknek ismerjük a koordinátáját.

Elvileg bármelyik városból el lehet jutni az összes többi városba. A feladat az, hogy határozzuk meg a legrövidebb útvonalat, amelyen végig lehet járni a városokat. Minden egyes várost kötelező egyszer meglátogatni, de minden egyes város pontosan egyszer látogatható

1. Topológia kiválasztása: a megoldás szempontjából az utazó érkezik egy városból és továbbmegy egy célvárosba → gyűrű topológia
2. Kohonen-háló bemenete: városok koordinátái



Kohonen-hálók

Utazó Ügynök Probléma (TSP) megoldása Kohonen-háló segítségével

3. Miben fogjuk megkapni a megoldást? Minden egyes neuron egy megoldást szolgáltat, és a megoldás, vagyis a meglátogatandó városok koordinátái a neuronháló súlytényezőiben lesznek kódolva a tanítást követően.

4. Neuronok kimenete:


$$y_i = \sqrt{\sum_{j=1}^N (w_{i,j} - x_j)^2}.$$

5. Győztes neuron: amelyre a pillanatnyi bemenet a legközelebb lesz egy neuron súlytényezőihez, vagyis a legkisebb kimenetet produkáló neuron.


6. Neuronok súlyainak módosítása a normalizált Hebb-szabállyal a győztes neuronra, Gauss- szomszédsági függvénnel a közeli neuronokra

Kohonen-hálók


Utazó Ügynök Probléma (TSP) megoldása Kohonen-háló segítségével




Kezdeti állapot



50. tanítási ciklus




100. tanítási ciklus




150. tanítási ciklus

Kohonen-hálók


Utazó Ügynök Probléma (TSP) megoldása Kohonen-háló segítségével




200. tanítási ciklus



250. tanítási ciklus



300. tanítási ciklus




350. tanítási ciklus

Kohonen-hálók

Színtérkép

Bemeneti adatok: színek RGB-koordinátái (15 db szín adatai a tanításhoz)

Kimenet: 20x30-as Kohonen-térkép



Kohonen hálók

- Számos területen alkalmaz(t)ák nem felügyelt tanulási képessége miatt
 - az olyan területeken, mint a klaszterezés, vizualizálás, adatszervezés, jellemzés és felfedezés
- Több változata is fellelhető a szakirodalomban,
 - Learning Vector Quantization (LVQ)
 - felügyelt tanítást igénylő feladatok esetén is alkalmazzák, mint például az osztályozás és mintafelismerés.

Felhasznált források

- <https://www.asimovinstitute.org/neural-network-zoo-prequel-cells-layers/>
- <https://www.asimovinstitute.org/neural-network-zoo/>
- M. L. Minsky and S. A. Papert, *Perceptrons* (expanded edition), The MIT Press, 1988.
- L. Fausett, *Fundamentals of Neural Networks: architectures, algorithms, and applications*, Prentice-Hall, 1994.
- R. Callan, *The Essence of Neural Networks*, Prentice Hall, 1999.
- S. Haykin, *Neural Networks: A Comprehensive Foundation* (2nd edition), Prentice-Hall, 1999.
- J. E. Moody and C. Darken, Fast learning in networks of locally-tuned processing units, *Neural Computation*, 1(2), pp. 281-294, 1989.
- L. O. Chua and L. Yang, Cellular neural networks: Theory. *IEEE Transactions on circuits and systems*, 35(10), pp. 1257-1272, 1988.
- T. Kohonen, The self-organizing map, *Proceedings of the IEEE*, 78(9), pp. 1464-1480, 1990.